תרגיל 2:
EM וזיהוי CPG לפי רצף

מוחמד עואודה

חלק 1- מימוש EM למציאת מטבע מוטה
מוטיבציה :

- תצפיות הן שאריות של תהליכים/מצבים חבויים
- מטרה: להסיק מסקנות על סוג המטבע (בין אם הוגן או מוטה) מדאטה נתון
- HMM – מודלי מקרוב חבויים ממדלים באופן הסטברותי את המצב החבוי של הטבעת
- מידול זה מאוד שימושי בביולוגיה, עיבוד שפה טבעית וניתוח סדרות זמן

הגדרת הבעיה

- מצבים חבויים למטבע: הוגן או מוטה
- תצפיות : עץ (H) או פלי (T)
- לא ידוע לנו: תנאי אתחול, הסתברויות המעבר והבליטה
- נתון לנו אך ורק תצפיות לסדרות של הטלות מטבע- ללא תיוג כלשהו לסוג המטבע

למה להשתמש באלגוריתם EM ?

- אי אפשר למקסם את הנראות עם המצבים החבויים (ללא תיוג)
- אלגוריתם EM מנסה להבין את מקור התצפיות שיש לנו ומעדכן את הפרמטרים בהתאם
- מתכנס לאופטימום מקומי
- נצטרך להריץ את EM כמה פעמים בגלל שהאתחול משפיע על ההתכנסות

Forward & Backward Algorithms

- Forward α: probability of prefix ending in each state.
- Backward β: probability of suffix beginning in each state.
- Posterior: $\gamma_t(k) = \frac{\alpha_t(k) * \beta_t(k)}{P(X)}$
- Identity : $P(X) = \sum_j \alpha_t(j) * \beta_t(j)$

אלגוריתם EM
צעד ראשון – חישוב הסתברויות פוסטריורית

- $\gamma_t(k)$ - תוחלת ההסתברות בלהיות במצב k בזמן t
- $\zeta_t(k,l)$ – הסתברות המעבר מהמצב k אל המצב l
- נחשב הנ"ל באמצעות α ו β
- יוצר לנו את מספר כל אחד מהמצבים בתוחלת

אלגוריתם EM
צעד שני – עדכון הפרמטרים

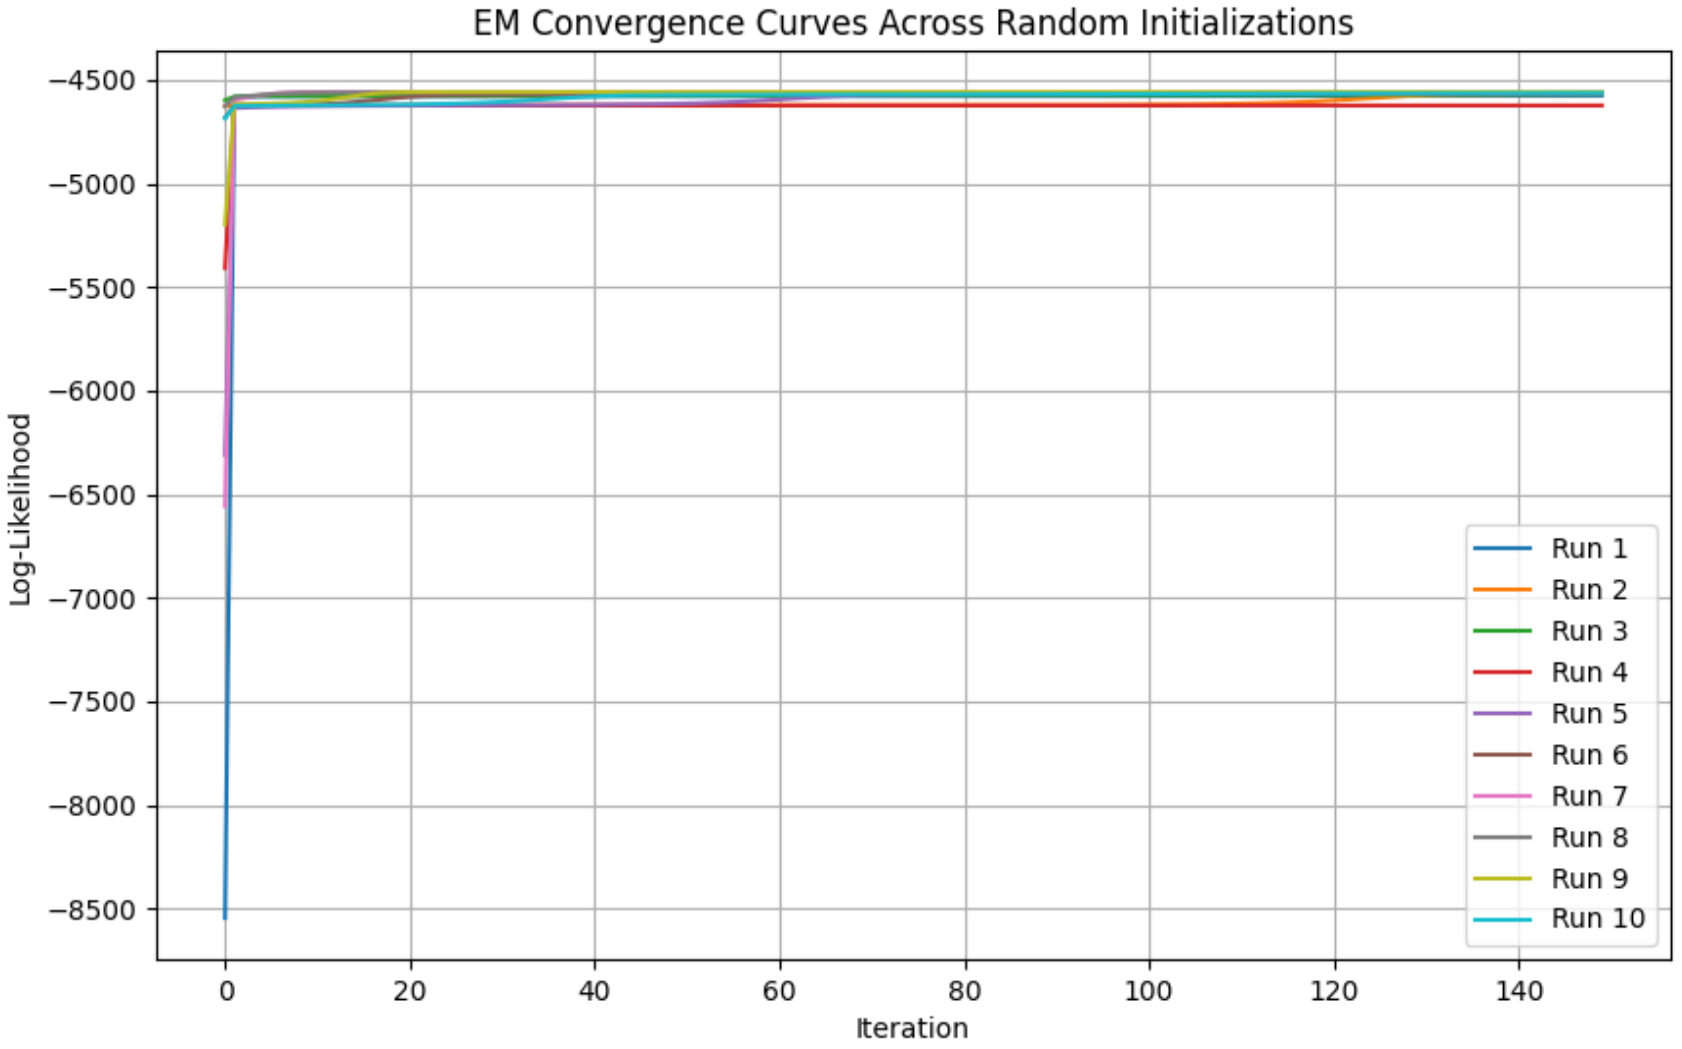
- **אתחול** $\gamma_0(k)$
- **מטריצת המעברים** : $\tau_{k,l} = \frac{N_{k,l}}{\sum_l N_{k,l}}$
- **מטריצת הפליטות** (emissions) : $e_k(x) = \frac{N_{k,x}}{\sum_x N_{k,x}}$
- **עדכון הפרמטרים ממקסם הנראות בתוחלת של כל סדרות הדאטה**

סט האימון

- 200 סדרות של הטלת מטבע
- חלוקת הדאטה לסט אימון, ולידציה וטסט ביחס 70,15 ו 15 בהתאמה
- 10 אתחולים שרירותיים לייעל הלמידה
- בחירת המודל הכי טוב לפי הולידציה דרך לוגרתם הנראות

השוואת מודלים

- לוג הנראות משתנה באופן דרמטי בין אתחולים שונים
- אתחולים רחוקים מאזור המקסימום ⟵ קפיצה בנראות באלגוריתם (תיקון)
- ולידציה הכי טובה היא 939.92- (בריצה 8)
- אפשר לראות התכנסות החל מאיטרציות מוקדמות


EM Convergence Curves Across Random Initializations
Log-Likelihood
Iteration
−4500
−5000
−5500
−6000
−6500
−7000
−7500
−8000
−8500
0
20
40
60
80
100
120
140
Run 1
Run 2
Run 3
Run 4
Run 5
Run 6
Run 7
Run 8
Run 9
Run 10

המודל הכי טוב (ריצה 8)

- **התפלגות התחלתית :**

  [0.353,0.647]

- **מטריצת מעבר:**

  [0.7395 0.2605]

  [0.0941 0.9059]

- **מטריצת התצפיות:**

  [0.9495 0.0505]

  [0.5076 0.4924]

ניתוח פרמטרים – האם התוצאות הגיוניות?

- **הסתברויות הפליטה**(Emission Probabilities) :
- **על פי המטריצה שקיבלנו:**
- **מצב 1:** [0.95,0.05] **- מטבע מוטה מאוד (כמעט תמיד מוציא עץ או פלי בהתאם למיפוי)**
- **מצב 2** : [0.51,0.49] **– מטבע הוגן (ההסברות מאוד קרובה ל 0.5)**
- **מסקנה: התוצאה הגיונית מאוד. האלגוריתם הצליח להפריד בבירור בין שני סוגי המטבעות כפי שנדרש בבעיה.**
- **הסתברויות המעבר** (Transition Probabilities) :
- **על פי המטריצה שקיבלנו: ההסתברות להישאר באותו מצב (ערכי האלכסון הן 0.91 ו 0.74) גבוהה מלהחליף מטבע.**
- **הסבר: זה דפוס הגיוני- הדילר לא מחליף מטבע כל זריקה שנייה, אלא זורק רצף של הטלות של אותו מטבע.**

ביצועי הטסט

- **ביצועי הטסט** : -969.99
- **קרוב מאוד לביצועי סט הולידציה ← שגיאת הכללה קטנה**
- **ביצועי המודל יציבים מול סדרות חדשות**

נקודות חשובות

- אלגוריתם EM ממדל את הבעיה בצורה שתופסת את המבנה של המצבים החבויים
- נדרשים כמה הרצות כדי לברוח ממקסימום מקומי ולא להיתקע בו
- הפרמטרים הנלמדים משקפים את הביאס של הדאטאסט
- הרצות forward וגם backwards מאוד עיקריים לחשב POSTERIOR INFERENCE

חלק 2: מימוש מודל לזיהוי איי CpG מדאטה קיים

מה הוא איי CpG?

- אזור ברצף דנ"א עם ריכוז גבוה של C→G
- חשוב לבקרת ביטוי גנים
- האתגר: לזהות את מיקום האי מתוך רצף ארוך

הגדרה פורמלית של המודל ה-HMM

ה- HMM שבו השתמשנו:

- **מצבים חבויים: N = לא־איי, C = איי**
- **פליטות: A,C,G,T**
- **פרמטרים:**
  - **π - הסתברות התחלה**
  - **A - מטריצת מעבר**
  - **B - מטריצת פליטה**

הנחות מרכזיות:

- **מרקוביות מדרגה ראשונה**
- **כל בסיס תלוי רק במצב**
- **תיוגי אמת אמינים (מהקובץ lbl)**
- **שני מצבים מספיקים למשימה**

איך אימנו את המודל (MLE)

למידת הפרמטרים מהדאטה:

- ספירת הופעות של A,C,G,T בכל מצב
- ספירת מעברים בין N↔C
- נרמול ל־MLE
- אין צורך ב־ EM - יש תיוגים אמת
- זמן אימון: 1.56 שניות עבור 1103 רצפים

שלב הניבוי: ויטרבי - Viterbi

ניבוי מיקומי האיים:

- אלגוריתם ויטרבי לרצף המצבים הסביר ביותר
- שימוש בלוג־הסתברויות
- פלט FASTA עם 'C'/'N'
- זמן ריצה לרצף יחיד: 0.007 שניות

תוצאות ודוגמה לפלט

- דוגמה קצרה מהפלט:

```
>chr2:213710-215709
NNNN
```

מוגבלות ושיפורים אפשריים

- שימוש ב־C reverse complement
- הוספת מצבים חבויים נוספים
- שימוש במודלי higher order
- שימוש בחבילות כמו hmmlearn

תודה רבה!