תרגיל 3 – עצים פילוגנטיים ושחזור רצף של אב קדמון

אלגוריתמים בביולוגיה חישובית – 76558

מוחמד עואודה

חלק 1 - מציאת הנוסחה לזמן האבולוציוני בין שני רצפים

בשלב הראשון של הפייפליין הפילוגנטי עלינו להעריך את המרחק האבולוציוני בין זוג רצפיDNA . מרחק זה מייצג את הזמן המשוער שעבר מאז שני הרצפים התפצלו מאב קדמון משותף. לצורך כך השתמשנו במודל האבולוציוני של **Jukes-Cantor (JC69)**.

מודל Jukes-Cantor
מודל Jukes-Cantor הוא מודל הסתברותי פשוט המתאר את תהליך המוטציות ברצפי DNA. המודל מניח כי:

- ארבעת הנוקלאוטידים A,C,G,T מופיעים בהסתברות שווה.
- קצב ההחלפה בין כל זוג נוקלאוטידים הוא זהה.
- כל אתר ברצף מתפתח באופן בלתי תלוי באתרים האחרים.
- תהליך המוטציות הומוגני לאורך הזמן.

תחת הנחות אלו ניתן לחשב את ההסתברות שנוקלאוטיד יישאר זהה לאחר זמן אבולוציוני t:

$$p_{same}(t) = \frac{1}{4} + \frac{3}{4}e^{-\frac{4}{3}t}$$

ואת ההסתברות שנוקלאוטיד ישתנה לנוקלאוטיד אחר:

$$p_{duff}(t) = \frac{1}{4} + \frac{1}{4}e^{-\frac{4}{3}t}$$

פונקציית הנראות
נניח כי אנו משווים שני רצפים מיושרים באורך n. נגדיר:

- p - מספר העמדות הזהות בין הרצפים
- q - מספר העמדות השונות

כך שמתקיים:

$$n = p + q$$

בהנחה שהעמדות בלתי תלויות, הנראות של שני הרצפים לאחר זמן אבולוציוני t היא:

$$L(t) = (p_{same}(t))^p \cdot (p_{diff}(t))^q$$

כדי להקל על החישוב משתמשים בלוג-נראות:

$$logL(t) = p\ log\ (p_{same}(t))^p \cdot q\ log(p_{diff}(t))^q$$

<u>מציאת הזמן האבולוציוני</u>
על מנת למצוא את ערך הזמן האבולוציוני המתאים ביותר, נגזור את פונקציית לוג-הנראות לפי t ונמצא את הערך שממקסם אותה. לאחר פתרון המשוואה מתקבלת נוסחת המרחק האבולוציוני של Jukes-Cantor .

נגדיר את שיעור האתרים השונים בין הרצפים:

$$d = \frac{q}{n}$$

ולפיכך מתקבלת הנוסחה:

$$t = -\frac{3}{4}\ln(1 - \frac{4}{3}d)$$

נוסחה זו מתקנת את שיעור ההבדלים הנצפה בין הרצפים על מנת לקחת בחשבון אפשרות של מוטציות מרובות באותו אתר לאורך הזמן.

<u>מימוש החישוב בקוד</u>

לצורך חישוב המרחק האבולוציוני מימשנו פונקציה שמקבלת שני רצפים מיושרים. הפונקציה משווה בין הרצפים אתר-אתר, סופרת את מספר העמדות השונות q, מחשבת את היחס $d = \frac{q}{n}$, ולאחר מכן מחשבת את המרחק האבולוציוני לפי נוסחת Jukes-Cantor.
בנוסף, מימשנו פונקציה הבונה **מטריצת מרחקים זוגיים** עבור כל הרצפים בקובץ הFASTA. המטריצה היא מטריצה סימטרית שבה כל תא מייצג את המרחק האבולוציוני בין שני רצפים. מטריצה זו תשמש בהמשך התרגיל לבניית העץ הפילוגנטי.

חלק 2 – מימוש אלגוריתמים למציאת העץ הפילוגנטי

לאחר שבחלק הראשון חישבנו את המרחק האבולוציוני בין זוג רצפים באמצעות מודל Jukes–Cantor, השתמשנו במטריצת המרחקים שהתקבלה כדי לבנות עצים פילוגנטיים המתארים את היחסים האבולוציוניים בין הרצפים.

בחלק זה מימשנו שני אלגוריתמים מרכזיים לבניית עצים פילוגנטיים:

- Neighbor Joining (NJ)
- UPGMA

שני האלגוריתמים מקבלים כקלט מטריצת מרחקים בין הרצפים, אך נשענים על הנחות שונות לגבי קצב האבולוציה ולכן עשויים להחזיר עצים שונים.

<u>מימוש אלגוריתם Neighbor Joining</u>

Neighbor Joining הוא אלגוריתם לבניית עץ פילוגנטי שאינו מניח קצב אבולוציוני אחיד בין כל הענפים. האלגוריתם פועל בצורה איטרטיבית ובכל שלב בוחר זוג צמתים אשר החיבור ביניהם ממזער פונקציית מרחק מתוקנת.

בכל איטרציה מבוצעים השלבים הבאים:

1. חישוב סכום המרחקים של כל צומת לשאר הצמתים

$$r_i = \sum D_{ij}$$

2. חישוב מטריצה מתוקנת

$$M_{ij} = (n-2)D_{ij} - r_i - r_j$$

כאשר n הוא מספר הצמתים הנוכחי.

3. בחירת הזוג (i,j) שעבורו Mij מינימלי
4. חישוב אורכי הענפים בין הצומת החדש לבין i ו- j
5. יצירת צומת פנימי חדש
6. עדכון מטריצת המרחקים

$$D(u,k) = \frac{D(i,k) + D(j,k) - D(i,j)}{2}$$

7. חזרה על התהליך עד שנותרים שני צמתים בלבד

התוצאה מוחזרת בפורמט Newick.

<u>פסאודו-קוד של Neighbor Joining</u>

```
NeighborJoining(D, ids):

    while number_of_nodes > 2:

        compute r_i = sum_j D[i,j]

        compute matrix M:
            M[i,j] = (n-2)*D[i,j] - r_i - r_j

        choose pair (i,j) with minimal M[i,j]

        compute branch lengths

        create new node u joining i and j

        update distances:
            D[u,k] = (D[i,k] + D[j,k] - D[i,j]) / 2

        update distance matrix

    connect the final two nodes
```

<u>מימוש אלגוריתם UPGMA</u>

UPGMA הוא אלגוריתם היררכי לבניית עצים פילוגנטיים המבוסס על הנחת שעון מולקולרי, כלומר שכל הענפים מתפתחים בקצב אבולוציוני אחיד.

האלגוריתם פועל כך:

1. כל רצף מתחיל כקלאסטר נפרד
2. בכל שלב נמצא זוג הקלאסטרים הקרובים ביותר
3. הקלאסטרים מאוחדים לקלאסטר חדש
4. גובה הצומת החדש הוא חצי מהמרחק ביניהם
5. המרחקים לשאר הקלאסטרים מחושבים כממוצע משוקלל
6. התהליך חוזר עד שנוצר עץ אחד

התוצאה מוחזרת בפורמט Newick.

<u>פסאודו-קוד של UPGMA</u>

```
UPGMA(D, ids):
```

initialize each sequence as its own cluster

while number_of_clusters > 1:

find clusters (i,j) with minimal distance

create new cluster u = merge(i,j)

compute height(u) = D[i,j] / 2

update distances using weighted average

return final tree

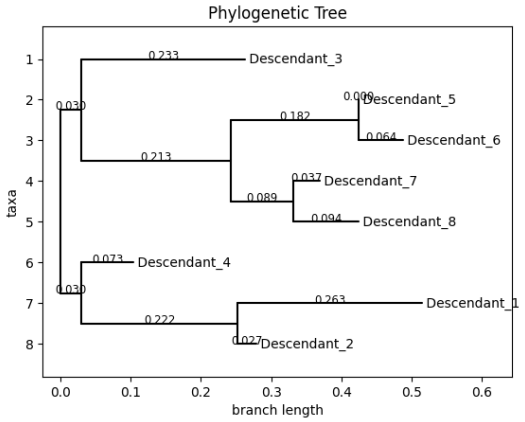
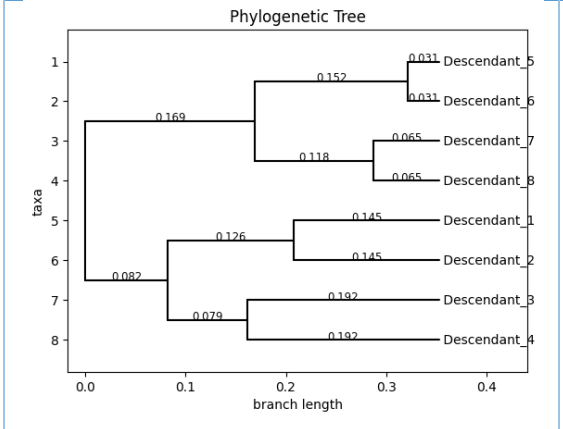
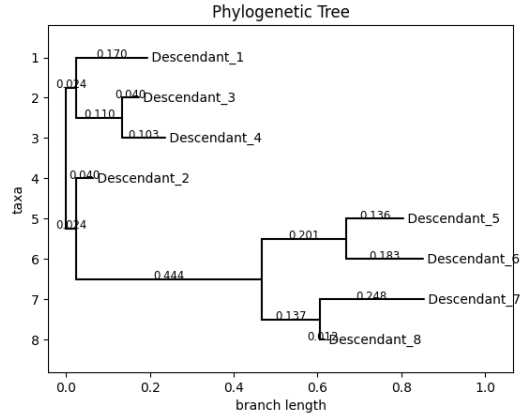
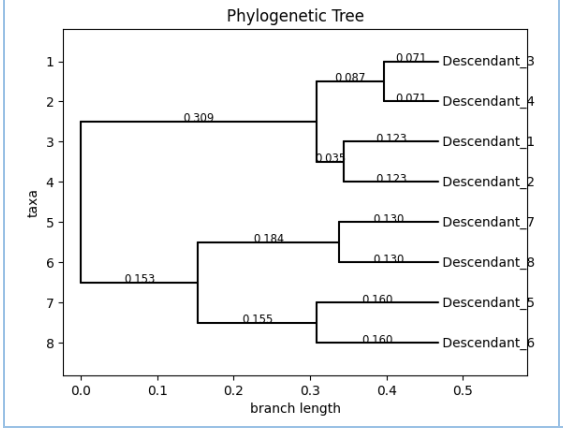
הצגת העצים

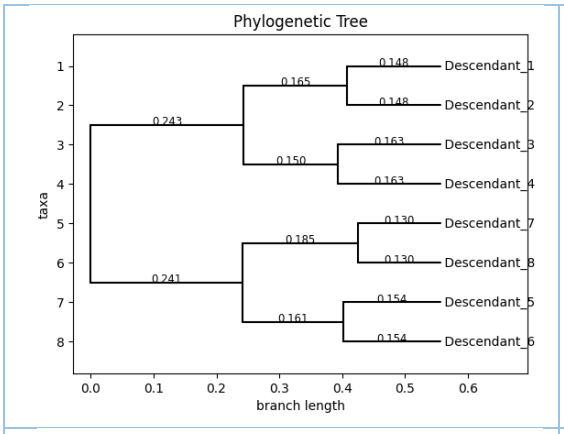
הרצנו את שני האלגוריתמים על כל קובצי הדאטה שסופקו עבור אורכי רצפים:

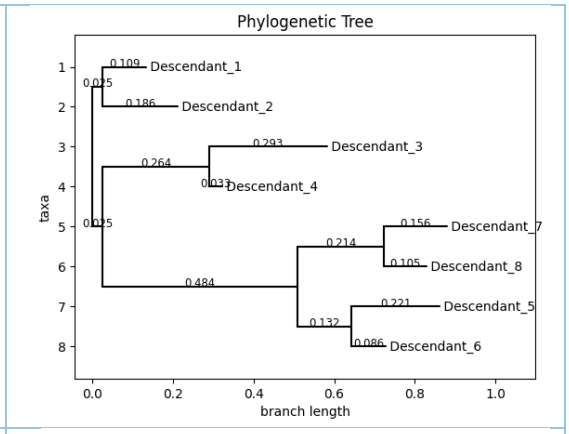
50, 100, 250, 500, 750, 1000, 1250,1500 בסיסים.

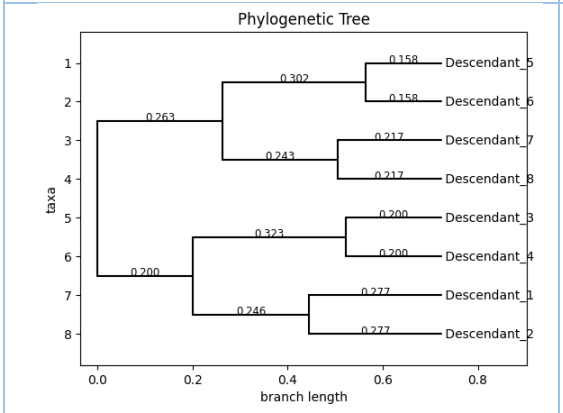
עבור כל קובץ התקבלו עצים באמצעות Neighbor Joining ו-UPGMA.

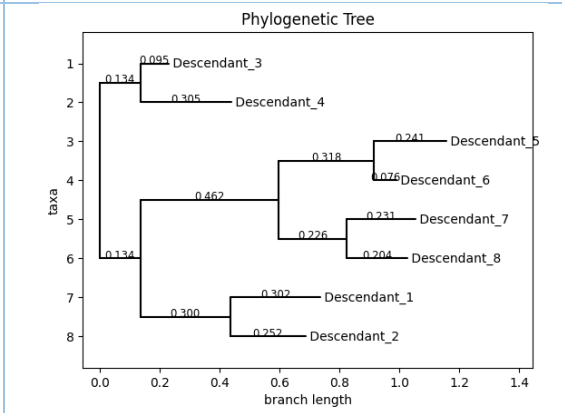
הם מופיעים למטה בטבלה(מ 50 עד 1500 בהתאם):

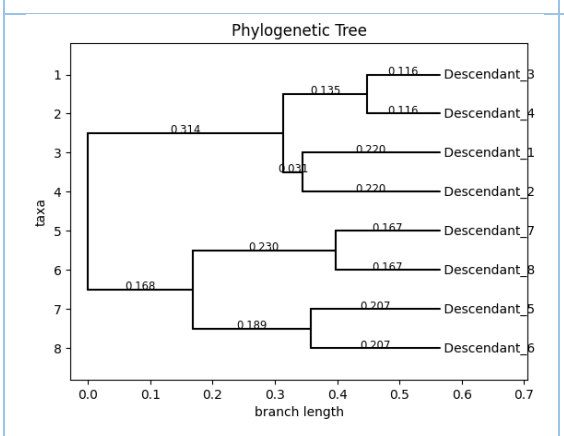
NJ	UPGMA
	
	

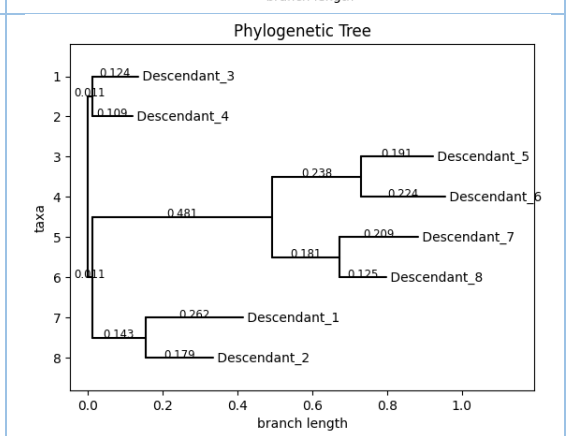

Phylogenetic Tree
Descendant_1
Descendant_2
Descendant_3
Descendant_4
Descendant_7
Descendant_8
Descendant_5
Descendant_6
0.148
0.165
0.148
0.243
0.163
0.150
0.163
0.130
0.185
0.130
0.241
0.154
0.161
0.154
taxa
branch length

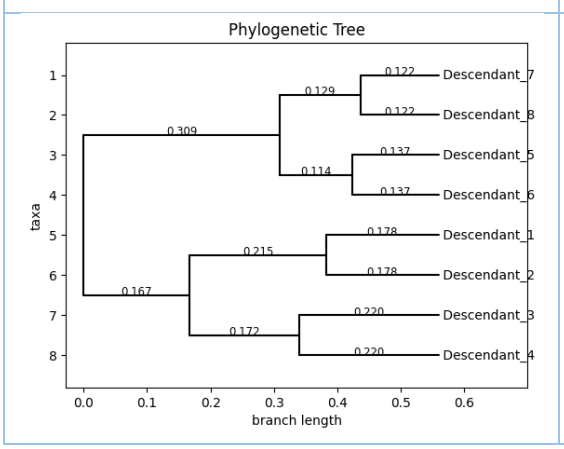

Phylogenetic Tree
Descendant_1
Descendant_2
Descendant_3
Descendant_4
Descendant_7
Descendant_8
Descendant_5
Descendant_6
0.109
0.025
0.186
0.293
0.264
0.033
0.025
0.156
0.214
0.105
0.484
0.221
0.132
0.086
taxa
branch length

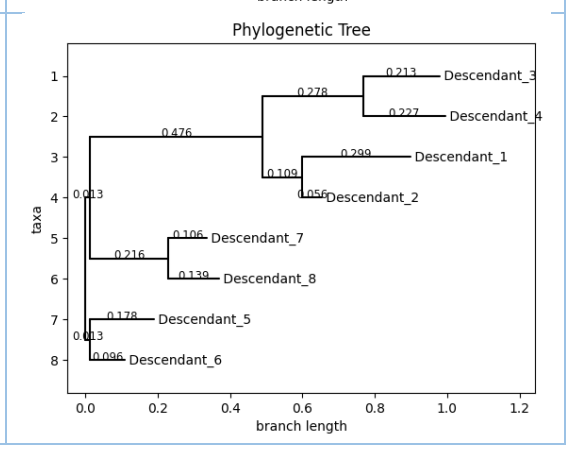

Phylogenetic Tree
Descendant_5
Descendant_6
Descendant_7
Descendant_8
Descendant_3
Descendant_4
Descendant_1
Descendant_2
0.158
0.302
0.158
0.263
0.217
0.243
0.217
0.200
0.323
0.200
0.200
0.277
0.246
0.277
taxa
branch length

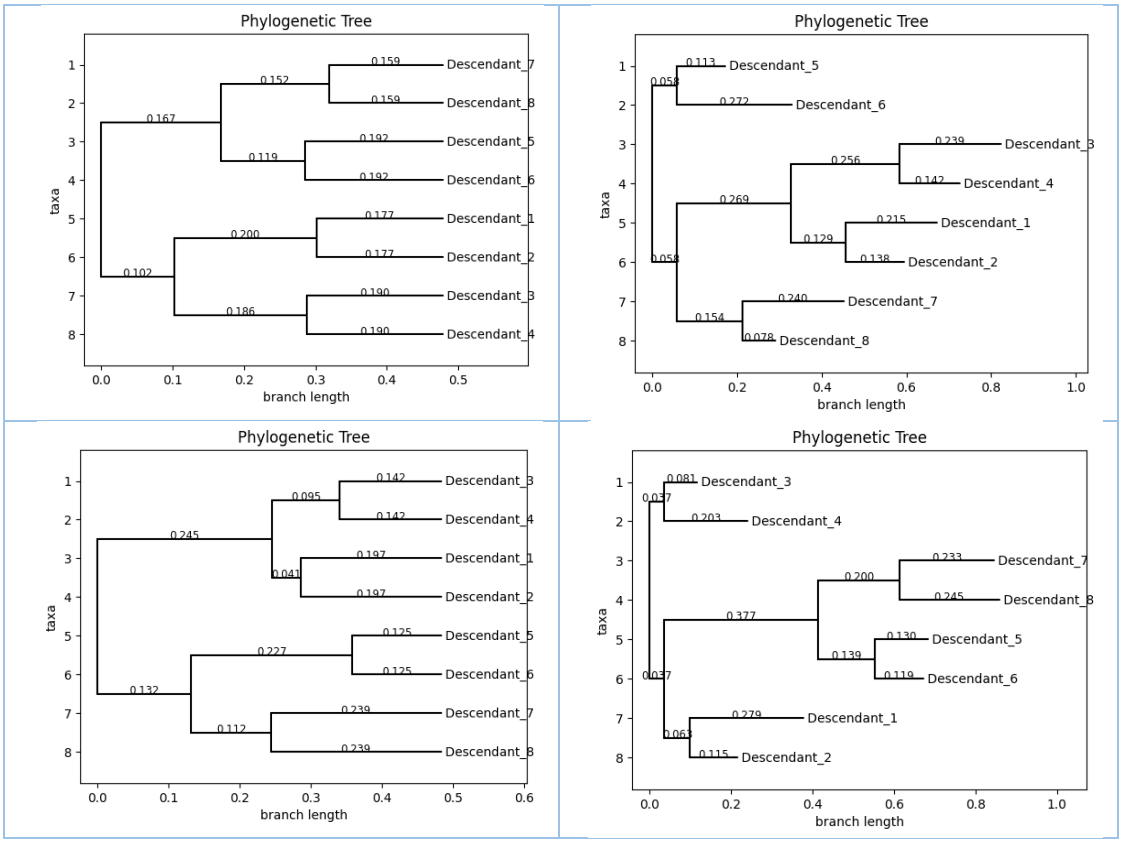

Phylogenetic Tree
Descendant_3
Descendant_4
Descendant_5
Descendant_6
Descendant_7
Descendant_8
Descendant_1
Descendant_2
0.095
0.134
0.305
0.241
0.318
0.076
0.462
0.231
0.226
0.204
0.134
0.302
0.300
0.252
taxa
branch length


Phylogenetic Tree
Descendant_3
Descendant_4
Descendant_1
Descendant_2
Descendant_7
Descendant_8
Descendant_5
Descendant_6
0.116
0.135
0.116
0.314
0.220
0.038
0.220
0.167
0.230
0.167
0.168
0.207
0.189
0.207
taxa
branch length


Phylogenetic Tree
Descendant_3
Descendant_4
Descendant_5
Descendant_6
Descendant_7
Descendant_8
Descendant_1
Descendant_2
0.124
0.011
0.109
0.191
0.238
0.224
0.481
0.209
0.181
0.011
0.125
0.262
0.143
0.179
taxa
branch length


Phylogenetic Tree
Descendant_7
Descendant_8
Descendant_5
Descendant_6
Descendant_1
Descendant_2
Descendant_3
Descendant_4
0.122
0.129
0.122
0.309
0.137
0.114
0.137
0.178
0.215
0.178
0.167
0.220
0.172
0.220
taxa
branch length


Phylogenetic Tree
Descendant_3
Descendant_4
Descendant_1
Descendant_2
Descendant_7
Descendant_8
Descendant_5
Descendant_6
0.213
0.278
0.227
0.476
0.299
0.109
0.013
0.056
0.106
0.216
0.139
0.178
0.013
0.096
taxa
branch length



האם העצים שהתקבלו הגיוניים

העצים שהתקבלו נראים הגיוניים מבחינה אבולוציונית. במספר עצים ניתן לזהות קיבוצים חוזרים של רצפים, למשל:

- Descendant_1עם Descendant_2
- Descendant_3עם Descendant_4
- Descendant_5עם Descendant_6
- Descendant_7עם Descendant_8

קיבוצים אלו מופיעים במספר עצים ובשני האלגוריתמים, דבר המצביע על כך שהמרחק האבולוציוני ביניהם קטן יחסית.

השפעת אורך הרצפים על מבנה העץ

בחנו כיצד מבנה העץ משתנה כאשר אורך הרצף גדל. עבור רצפים קצרים יחסית (כגון 50 או 100 בסיסים) מתקבלים לעיתים קיבוצים שונים, משום שחישוב המרחקים מבוסס על מספר קטן של אתרים ולכן רגיש יותר לרעש סטטיסטי.

לעומת זאת, כאשר אורך הרצף גדל (למשל 500 בסיסים ומעלה), מתקבלים עצים יציבים יותר והקיבוצים בין הרצפים נשמרים בצורה עקבית יותר.

השוואה בין Neighbor Joining לביןUPGMA

בשני האלגוריתמים מתקבלים לעיתים קיבוצים דומים, אך מבנה העץ הכולל אינו תמיד זהה.

UPGMAמניח קצב אבולוציוני אחיד ולכן מתקבלים עצים מאוזנים יחסית, בעוד Neighbor Joiningאינו מניח קצב כזה ולכן מאפשר מבנה גמיש יותר של העץ.

<u>מסקנות:</u>

בחלק זה מימשנו שני אלגוריתמים לבניית עצים פילוגנטיים מתוך מטריצת המרחקים: UPGMA-הצגנו את העצים עבור כל קובצי הדאטה, הדפסנו ו Neighbor Joining. אותם בפורמט Newickוהצגנו אותם בצורה גרפית. התוצאות שהתקבלו נראות הגיוניות, ונמצא כי ככל שאורך הרצפים גדל מתקבלים עצים יציבים יותר.

חלק 3 - מימוש האלגוריתם של פלזנשטיין

לאחר שבחלקים הקודמים חישבנו מרחקים אבולוציוניים ובנינו עצים פילוגנטיים, בחלק זה מימשנו את אלגוריתם הקיצוץ (pruning) של פלזנשטיין (Felsenstein, 1981) תחת מודל האבולוציה של ג׳וקס וקנטור. אלגוריתם זה מאפשר לנו לחשב את הנראות (Likelihood) של עץ פילוגנטי נתון, ולשחזר את הרצף הסביר ביותר של האב הקדמון בשורש העץ.

<u>מהלך האלגוריתם</u>

אלגוריתם פלזנשטיין מחשב את נראות העץ באמצעות מעבר מלמטה למעלה (bottom-up), מהעלים לשורש. האלגוריתם מבוסס על ההנחות הבאות:

עץ פילוגנטי בינארי עם אורכי ענפים ידועים; מודל ג׳וקס וקנטור לאבולוציה של רצפים עם $\alpha = \frac{1}{3}$; עמדות בלתי תלויות ברצף; והתפלגות סטציונרית אחידה על ארבעת הבסיסים: $\pi_i = \frac{1}{4}$.

<u>שלב 1: אתחול בעלים</u>

עבור כל עלה v עם בסיס נצפה x_v בעמדה מסוימת, וקטור הנראות מוגדר כך:

$$L_v(i) = \begin{cases} 1 & i = x_v \\ 0 & i \neq x_v \end{cases}$$

כלומר, הנראות של הבסיס הנצפה בעלה היא 1, ושל כל בסיס אחר היא 0.

<u>שלב 2: רקורסיה בצמתים פנימיים</u>

עבור כל צומת פנימי v עם ילדים c1, c2, ..., הנראות מחושבת לפי נוסחת הרקורסיה:

$$L_v(i) = \prod_{c \in children(v)} [\sum P_{ij}(t_{vc}) \cdot L_c(j)]$$

כאשר $P_{ij}(t)$ היא הסתברות המעבר ממצב i למצב j בזמן t, לפי מודל ג׳וקס וקנטור:

$$P_{ii}(t) = \frac{1}{4} + \frac{3}{4} e^{-\frac{4}{3}t}$$

$$P_{ij}(t) = \frac{1}{4} - \frac{1}{4} e^{-\frac{4}{3}t}, i \neq j$$

עבור כל צומת פנימי, המכפלה מבוצעת על פני כל הילדים, וסכום המעבר מחושב על פני כל ארבעת הבסיסים האפשריים של הילד.

שלב 3: חישוב נראות השורש

לאחר חישוב וקטור הנראות בשורש, הנראות של אתר בודד מחושבת כסכום משוקלל על פני ההתפלגות הסטציונרית:

$$L_{site} = \frac{1}{4}\sum_{i \in A} L_{root}(i)$$

שלב 4: התאמה לרצף בעל מספר עמדות

בעולם אמיתי, רצפים מכילים מספר רב של עמדות. תחת הנחת עמדות בלתי תלויות, הנראות הכוללת היא מכפלת הנראויות של כל אתר, ולוג הנראות הכולל הוא סכום לוגי הנוראיות:

$$l = lnL = \sum_{s=1}^{N} lnL_{site}^{(s)}$$

במימוש, חישבנו את וקטורי הנראות עבור כל העמדות בו-זמנית באמצעות מטריצות NumPy בגודל (seq_length × 4), כך שהחישוב מבוצע ביעילות באמצעות כפל מטריצות במקום לולאות על עמדות בודדות.

ניתוח זמן ריצה

סיבוכיות הזמן של אלגוריתם פלזנשטיין היא $O(N \cdot k^2 \cdot n)$, כאשר N הוא אורך הרצף (מספר העמדות), k הוא מספר המצבים האפשריים (4 עבור DNA), ו-n הוא מספר הצמתים בעץ. בפועל, מכיוון ש-k=4 קבוע, הסיבוכיות האפקטיבית היא $O(N \cdot n)$. במימוש הווקטורי שלנו, כפל המטריצות מבוצע ביעילות עבור כל האתרים בו-זמנית.

השוואת תוצאות: NJ מול UPGMA

הרצנו את אלגוריתם פלזנשטיין על עצים שנבנו בשתי השיטות עבור כל אורכי הרצפים. להלן טבלת התוצאות:

אורך רצף	NJ LogLik	UPGMA LogLik	NJ Identity	UPGMA Identity	NJ Dist	UPGMA Dist
50	-329.43	-333.37	82.0%	86.0%	0.2058	0.1550
100	-702.53	-713.54	79.0%	85.0%	0.2464	0.1674
250	-1976.72	-1987.47	80.4%	78.0%	0.2272	0.2604
500	-4504.42	-4513.97	64.2%	65.6%	0.4866	0.4603
750	-6110.49	-6132.08	76.9%	76.0%	0.2756	0.2892
1000	-7993.19	-8053.43	72.9%	76.5%	0.3363	0.2819
1250	-10225.52	-10292.16	64.9%	81.8%	0.4737	0.2090
1500	-11848.74	-11920.40	73.4%	83.6%	0.3285	0.1851

ניתוח התוצאות

מהטבלה ניתן להסיק מספר מסקנות:

1. לוג-נראות: בכל אורכי הרצפים, NJ מקבל ערך לוג-נראות גבוה יותר (פחות שלילי) מאשר UPGMA. זה צפוי, מכיוון ש-NJ אינו מניח שעון מולקולרי ולכן מספק התאמה טובה יותר לנתונים. הנתונים סומלצו באמצעות מטריצת ג'וקס וקנטור ללא הנחת שעון מולקולרי, ולכן NJ מתאים יותר.

2. לוג-נראות מנורמל (לאתר): ערכי לוג-הנראות יורדים באופן ליניארי עם אורך הרצף, דבר צפוי מכיוון שכל אתר תורם באופן עצמאי ללוג-הנראות. לוג-הנראות לאתר נשאר יציב יחסית.

3. דיוק שיחזור האב הקדמון: שיעור הזהות בין הרצף המשוחזר לרצף האב הקדמון האמיתי נע בין 64% ל-86% בהתאם לאורך הרצף ולשיטה. באופן כללי, UPGMA נוטה לתת שיחזור מדויק יותר ברצפים ארוכים (1000 בסיסים ומעלה), למרות שערכי הנראות שלו נמוכים יותר. זאת מכיוון שהעצים האולטרמטריים של UPGMA ממקמים את השורש במרכז העץ, קרוב יותר לאב הקדמון האמיתי.

4. השפעת אורך הרצף: ברצפים קצרים (50-100 בסיסים) דיוק השיחזור משתנה מאוד בשל רעש סטטיסטי. ברצפים ארוכים יותר (750 בסיסים ומעלה), ניתן לראות שהשיחזור מתייצב ומשתפר, מכיוון שיש יותר מידע סטטיסטי לחישוב מרחקים אבולוציוניים מדויקים ולבניית עץ נכון.

שחזור רצף האב הקדמון

שחזור הרצף בשורש מבוצע באמצעות אלגוריתם פלזנשטיין. לאחר חישוב וקטור הנראות בשורש עבור כל עמדה, הבסיס המשוחזר נבחר כבסיס בעל הנראות הגבוהה ביותר:

$$\hat{x}_r = argmax_{i\in A}[\pi_i \cdot L_r(i)] = argmax_{i\in A} L_r(i)$$

כאשר ההתפלגות הסטציונרית אחידה ($\pi_i = \frac{1}{4}$:), מספיק למצוא את הבסיס עם ערך $L_r(i)$ המקסימלי. עבור רצף עם מספר עמדות, השיחזור מבוצע באופן עצמאי לכל עמדה.

דוגמה מפורטת לשחזור

נדגים את השיחזור עבור רצפים באורך 100 בסיסים עם עץ NJ:

לוג-נראות העץ: -702.53

שיעור זהות עם האב הקדמון האמיתי: 79.00% (79 מתוך 100 בסיסים זהים)

מרחק אבולוציוני מהרצף המשוחזר לרצף האמיתי: 0.2464

לשם השוואה, עם עץ UPGMA עבור אותם נתונים: זהות של 85.00% ומרחק אבולוציוני של 0.1674. ההבדל נובע ממיקום שונה של שורש העץ בשתי השיטות.

מרחק אבולוציוני מהאב הקדמון כפונקציה של אורך הרצף

אורך רצף	NJ Identity %	NJ Evol. Distance	UPGMA Identity %	UPGMA Evol. Distance
50	82.0%	0.2058	86.0%	0.1550
100	79.0%	0.2464	85.0%	0.1674
250	80.4%	0.2272	78.0%	0.2604
500	64.2%	0.4866	65.6%	0.4603
750	76.9%	0.2756	76.0%	0.2892
1000	72.9%	0.3363	76.5%	0.2819
1250	64.9%	0.4737	81.8%	0.2090
1500	73.4%	0.3285	83.6%	0.1851

מהטבלה ניתן לראות שהמרחק האבולוציוני בין הרצף המשוחזר לרצף האב הקדמון האמיתי אינו יורד באופן מונוטוני עם אורך הרצף. הסיבה היא שהשיחזור תלוי גם באיכות העץ שנבנה וגם באורכי הענפים. ברצפים קצרים, הרעש הסטטיסטי משפיע על בניית העץ עצמו, ובמקרים מסוימים (כמו רצפים באורך 500) גם רצפים ארוכים יחסית עלולים להניב שיחזור פחות מדויק אם הענפים ארוכים במיוחד.

השוואה נוספת: המשוחזר מול הצאצאים

ניתן לצפות שהרצף המשוחזר יהיה קרוב יותר לצאצאים מאשר הצאצאים זה לזה, מכיוון שהוא ממוקם בשורש העץ. בפועל, הרצף המשוחזר מהווה מעין "ממוצע אבולוציוני" של הצאצאים, כלומר בכל עמדה הוא נוטה לבחור את הבסיס הנפוץ ביותר מבין הצאצאים בהינתן מבנה העץ.

שימוש בכלי AI

במהלך העבודה על התרגיל נעזרנו בכלי ChatGPT באופן נקודתי. השימוש העיקרי היה לצורך הבהרת שגיאות שנתקלנו בהן בזמן הרצת הקוד, כגון שגיאות בטיפוסי נתונים ובהתאמה בין פורמט עץ Newick לבין הספרייה Bio.Phylo. בנוסף, נעזרנו בכלי כדי לרענן את ההבנה של נוסחת הרקורסיה של אלגוריתם פלזנשטיין כפי שהוצגה בהרצאה, ולוודא שהמימוש שלנו תואם את הנוסחה המתמטית. כלל הקוד נכתב על ידינו באופן עצמאי, והכלי שימש אך ורק לבירור ספקות ולפתרון באגים.